


GitHub & CVE: Ekosistem Big Data Keamanan Siber

Praja Lohphimesti Subiarto | 24083010060 | Big Data Kelas C

1. Pendahuluan

Di era digitalisasi yang pesat, keamanan perangkat lunak menjadi tantangan besar industri teknologi. Dua platform yang memainkan peran sentral dalam ekosistem keamanan siber global adalah GitHub sebagai repositori kode sumber terbesar di dunia dengan lebih dari 100 juta pengembang dan CVE (Common Vulnerabilities and Exposures), yaitu sistem penomoran standar untuk kerentanan perangkat lunak yang dikelola oleh MITRE Corporation dan didukung oleh NVD (National Vulnerability Database) milik NIST.

Relevansi keduanya sebagai studi kasus big data sangat tinggi, GitHub menghasilkan miliaran commit, pull request, dan laporan isu setiap tahun, sementara basis data CVE telah mengakumulasi lebih dari 230.000 entri kerentanan yang terus bertambah ratusan entri baru setiap minggunya. Keduanya saling terhubung melalui fitur *Dependabot* dan *Security Advisories* yang secara langsung mereferensikan nomor CVE. Gambar 1 di bawah menunjukkan arsitektur alur ekosistem big data ini secara keseluruhan.



Gambar 1. Arsitektur ekosistem big data keamanan siber berbasis GitHub & CVE

Gambar 1. Arsitektur ekosistem big data keamanan siber berbasis GitHub & CVE

2. Analisis Aspek Big Data

Aspek	Deskripsi pada Ekosistem GitHub/CVE
Volume	>330 juta repositori GitHub; >230.000 entri CVE aktif di NVD
Velocity	Ribuan commit/menit di GitHub; ratusan CVE baru per minggu
Variety	Kode, metadata, diff, issue, JSON/XML CVE feed, skor CVSS, CWE
Veracity	Kualitas deskripsi CVE bervariasi; terdapat duplikasi & false positive
Value	Deteksi kerentanan otomatis, audit dependensi, riset keamanan siber

Tabel 1. Ringkasan aspek big data pada ekosistem GitHub/CVE

Volume. GitHub menyimpan lebih dari 330 juta repositori publik dan privat, menghasilkan data dalam skala petabyte. Setiap commit menyimpan diff, metadata author, timestamp, dan referensi ke isu atau pull request. NVD menyediakan seluruh basis data CVE dalam format JSON yang dapat diunduh dan saat ini mencakup data sejak tahun 1999. Skala volume ini menjadikan penyimpanan dan pengindeksan sebagai tantangan tersendiri.

Velocity. GitHub mencatat rata-rata lebih dari 1 juta push event per hari. Di sisi lain, NVD menerbitkan pembaruan data CVE secara inkremental setiap hari, dan platform seperti Snyk atau GitHub Advanced Security harus menyinkronkan data tersebut secara hampir real-time agar peringatan kerentanan tetap relevan. Kecepatan munculnya eksploitasi baru (zero-day) menuntut pipeline data yang sangat responsif.

Variety. Data dalam ekosistem ini sangat heterogen: kode sumber dalam ratusan bahasa pemrograman, file konfigurasi (YAML/JSON/TOML), laporan isu dalam bahasa alami, feed CVE dalam format JSON/XML, skor

CVSS (numerik), referensi CWE, serta patch diff. Integrasi antar-format ini membutuhkan pipeline ETL yang fleksibel dan robust.

3. Usulan Pengembangan Ekosistem

Meskipun ekosistem GitHub/CVE sudah maju, beberapa celah masih dapat diperbaiki untuk memaksimalkan manfaatnya:

Integrasi Lintas Platform	Hubungkan CVE dengan SBOM (Software Bill of Materials) dan OSV.dev secara otomatis, sehingga setiap rilis paket dapat langsung diperiksa kerentanannya tanpa intervensi manual.
AI untuk Triase Otomatis	Manfaatkan LLM yang dilatih pada data GitHub untuk mengklasifikasikan severity CVE secara otomatis dan menyarankan patch, mengurangi backlog entri yang masih berstatus 'AWAITING ANALYSIS'.
Aksesibilitas Lokal	Kembangkan antarmuka berbahasa Indonesia dan integrasi dengan GitLab self-hosted yang umum dipakai lembaga pemerintah, agar pengembang lokal dapat memanfaatkan ekosistem keamanan ini secara penuh.

GitHub dan CVE secara bersama membentuk infrastruktur big data keamanan siber yang esensial. Dengan mengatasi tantangan veracity data, mempercepat velocity analisis, dan meningkatkan aksesibilitas global, ekosistem ini berpotensi menjadi tulang punggung keamanan perangkat lunak dunia yang lebih proaktif dan inklusif.